

# Методы оптимизации

## Введение в проксимальные методы

Александр Катруца

Московский физико-технический институт

28 апреля 2020 г.

На прошлой лекции

- ▶ Метод Ньютона

## На прошлой лекции

- ▶ Метод Ньютона
- ▶ Квазиньютоновские методы

## На прошлой лекции

- ▶ Метод Ньютона
- ▶ Квазиньютоновские методы
- ▶ Метод Barzilai-Borwein

## На прошлой лекции

- ▶ Метод Ньютона
- ▶ Квазиньютоновские методы
- ▶ Метод Barzilai-Borwein
- ▶ Квазиньютоновские методы с ограниченной памятью

# От градиентного спуска к методу проекции градиента

- ▶ Градиентный спуск

$$\begin{aligned}x_{k+1} &= \arg \min_x \left( \langle f'(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|_2^2 \right) \\&= \arg \min_x \left\| x - \left( x_k - \frac{1}{L} f'(x_k) \right) \right\|_2^2\end{aligned}$$

- ▶ Пусть есть ограничение вида  $x \in C$ , тогда

$$x_{k+1} = \arg \min_{x \in C} \left\| x - \left( x_k - \frac{1}{L} f'(x_k) \right) \right\|_2^2 = \pi_C \left( x_k - \frac{1}{L} f'(x_k) \right)$$

- ▶ Получили метод проекции градиента

# Проекция и её свойства

## Определение

Для данной точки  $y \in \mathbb{R}^n$  решение следующей задачи

$$\min_{x \in C} \|x - y\|_2$$

называется проекцией точки  $y$  на множество  $C$

## Теорема

Если множество  $C$  выпукло и замкнуто, то проекция существует и единственна

# Нерастягивающий оператор

## Определение

Оператор  $f$  называется нерастягивающим, если

$$\|f(x) - f(y)\| \leq \|x - y\|,$$

то есть константа Липшица равна 1

**Q:** как называется оператор с константой Липшица меньше 1?



## Теорема

Оператор проекции является нерастягивающим.

## Доказательство

1. По свойству проекции, для любой точки  $y_1$

$$\langle y_1 - \pi_C(y_1), x - \pi_C(y_1) \rangle \leq 0, \quad \forall x \in C$$

2. Пусть  $x = \pi_C(y_2)$ , тогда

$$\langle y_1 - \pi_C(y_1), \pi_C(y_2) - \pi_C(y_1) \rangle \leq 0$$

$$\langle \pi_C(y_2) - y_2, \pi_C(y_2) - \pi_C(y_1) \rangle \leq 0$$

3. Сложим

$$\langle \pi_C(y_2) - \pi_C(y_1), \pi_C(y_2) - \pi_C(y_1) \rangle \leq \langle \pi_C(y_2) - \pi_C(y_1), y_2 - y_1 \rangle$$

4. По неравенству КБШ

$$\|\pi_C(y_2) - \pi_C(y_1)\| \leq \|y_2 - y_1\|$$

# Firmly non-expansiveness

## Определение

Оператор  $f$  называется firmly non-expansive, если

$$\|f(x) - f(y)\|_2^2 \leq \langle f(x) - f(y), x - y \rangle$$

## Теорема

Оператор проекции является firmly non-expansive:

$$\|\pi_C(x) - \pi_C(y)\|_2^2 \leq \langle \pi_C(x) - \pi_C(y), x - y \rangle$$

# Сходимость

## Лемма

Если  $x^*$  решение задачи, то  $x^* = \pi_C(x^* - \alpha f'(x^*))$

## Доказательство

1.  $g^* \equiv f'(x^*)$
2. Общее условие оптимальности  $\langle g^*, x - x^* \rangle \geq 0, \forall x \in C$
3. Свойство проекции  $z = \pi_C(y)$

$$\langle z - y, x - z \rangle \geq 0, \forall x \in C$$

4. Подставим  $z = x^*$  и  $y = x^* - \alpha g^*$  и разделим на  $\alpha > 0$

$$\langle g^*, x - x^* \rangle \geq 0$$

- ▶  $\|x_{k+1} - x^*\|_2^2 = \|\pi_C(x_k - \alpha f'(x_k)) - \pi_C(x^* - \alpha f'(x^*))\|_2^2 \leq \|x_k - x^* - \alpha(f'(x_k) - f'(x^*))\|_2^2 = \|x_k - x^*\|_2^2 + \alpha^2 \|f'(x_k) - f'(x^*)\|_2^2 - 2\alpha \langle f'(x_k) - f'(x^*), x_k - x^* \rangle$
- ▶ Если функция выпукла и дифференцируема, а также градиент Липшицев с константой  $L$  тогда

$$\langle f'(x) - f'(y), x - y \rangle \geq \frac{1}{L} \|f'(x) - f'(y)\|_2^2$$

- ▶  $\|x_{k+1} - x^*\|_2^2 \leq \|x_k - x^*\|_2^2 + \alpha(\alpha - \frac{2}{L}) \|f'(x_k) - f'(x^*)\|_2^2$
- ▶  $\alpha \leq \frac{2}{L} \rightarrow r_{k+1} \leq r_k \leq r_0$

- ▶  $f(x_{k+1}) \leq f(x_k) + \langle f'(x_k), x_{k+1} - x_k \rangle + \frac{1}{2} \|x_{k+1} - x_k\|_2^2 =$   
 $f(x_k) + \langle f'(x_k), \pi_C(x_k - \alpha f'(x_k)) - \pi_C(x_k) \rangle + \frac{1}{2} \|x_{k+1} - x_k\|_2^2$
- ▶  $\|\pi_C(x_k - \alpha f'(x_k)) - \pi_C(x_k)\|_2^2 \leq$   
 $\langle \pi_C(x_k - \alpha f'(x_k)) - \pi_C(x_k), -\alpha f'(x_k) \rangle$
- ▶  $-\alpha^{-1} \|x_{k+1} - x_k\|_2^2 \geq \langle f'(x_k), \pi_C(x_k - \alpha f'(x_k)) - \pi_C(x_k) \rangle$
- ▶  $f(x_{k+1}) \leq f(x_k) + \left(\frac{L}{2} - \frac{1}{\alpha}\right) \|x_{k+1} - x_k\|_2^2 =$   
 $f(x_k) - \frac{L}{2} \|\pi_C(x_k - \alpha f'(x_k)) - x_k\|_2^2$
- ▶  $f_k \geq f_{k+1} + \frac{L}{2} \|\pi_C(x_k - \alpha f'(x_k)) - x_k\|_2^2$
- ▶ Складываем

$$f_0 - f^* \geq f_{k+1} - f^* + \frac{L}{2} \sum_{i=0}^k \|\pi_C(x_i - \alpha f'(x_i)) - x_i\|_2^2$$

- ▶ Левая часть конечна, значит ряд сходится и

$$\lim_{k \rightarrow \infty} \|\pi_C(x_k - \alpha f'(x_k)) - x_k\| = 0$$

- ▶ Получили сходимость!
- ▶ Если использовать неравенства-следствия выпуклости  $f$ , то можно показать сходимость вида  $\mathcal{O}(1/k)$

## Примеры множеств и проекции на них

- ▶  $C = \{x \mid a_i \leq x_i \leq b_i\} \rightarrow \pi_C(y) = \text{clip}_{[a_i, b_i]}(y)$
- ▶  $C = \{x \mid Ax = b\} \rightarrow \pi_C(y) = y - A^\top (AA^\top)^{-1}(Ay - b)$
- ▶  $C = \{x \mid \|x\|_2 \leq 1\} \rightarrow \pi_C(y) = y/\|y\|_2$
- ▶  $C = \mathbb{S}_+^n \rightarrow \pi_C(V) = \sum_{i=1}^n \max(0, \lambda_i) u_i u_i^\top$

# Pro & Contra

## Pro

- ▶ часто можно аналитически вычислить проекцию
- ▶ сходимость аналогична градиентному спуску в безусловной оптимизации
- ▶ обобщается на негладкий случай

## Contra

- ▶ при больших  $n$  аналитическое вычисление проекции может быть слишком затратно
- ▶ при обновлении градиента может теряться структура задачи

# Проксимальный метод

После дискретизации ОДУ

$$\frac{dx}{dt} = -f'(x(t))$$

вида

$$\frac{x_{k+1} - x_k}{\alpha} = -f'(\textcolor{red}{x}_{k+1}),$$

получим, что

$$\left( \frac{1}{2\alpha} \|u - x_k\|_2^2 + f(u) \right)' (x_{k+1}) = 0$$
$$x_{k+1} = \arg \min_u \left( f(u) + \frac{1}{2\alpha} \|u - x_k\|_2^2 \right) = \textit{prox}_{\alpha f}(x_k)$$

- ▶ Сильно выпуклая функция
- ▶ Единственный минимум



# Неподвижная точка проксимального оператора

## Теорема

Точка  $x^*$  является решением задачи тогда и только тогда, когда

$$x^* = \text{prox}_f(x^*)$$

## Доказательство

1. Если  $x^*$  решение задачи, то  $f(x) \geq f(x^*)$ , тогда

$$f(x) + \frac{1}{2}\|x - x^*\|_2^2 \geq f(x^*) = f(x^*) + \frac{1}{2}\|x^* - x^*\|_2^2$$

2.  $x^*$  точка минимума функции  $f(x) + \frac{1}{2}\|x - x^*\|_2^2$
3. Следовательно  $x^* = \text{prox}_f(x^*)$
4. Из критерия первого порядка  $\bar{x}$  минимизирует  $f(x) + \frac{1}{2}\|x - v\|_2^2$  iff  $f'(\bar{x}) + (x - v) = 0$
5.  $\bar{x} = v = x^* \rightarrow f'(x^*) = 0$

# Интерпретация

Пусть  $f$  дважды дифференцируемы и сильно выпукла.

- ▶ Градиентный спуск как аппроксимация проксимального метода

$$x_{k+1} = \text{prox}_{\alpha f}(x_k) = (I + \alpha f')^{-1}(x_k) \approx x_k - \alpha f'(x_k) + o(\alpha), \quad \alpha \rightarrow 0$$

- ▶ Проксимальный метод для аппроксимации второго порядка
- $$\hat{f}(v) = f(x) + \langle f'(x), v - x \rangle + \frac{1}{2} \langle v - x, f''(x)(v - x) \rangle$$

$$\text{prox}_{\alpha \hat{f}}(x_k) = x_k - (f''(x_k) + (1/\alpha)I)^{-1} f'(x_k)$$

## Случай разделения переменных

Если  $f$  имеет вид

$$f(x) = \sum_{i=1}^n f_i(x_i)$$

тогда

$$\text{prox}_f(v)_i = \text{prox}_{f_i}(v_i)$$

- ▶ Параллельное вычисление компонент
- ▶ Консенсусная форма постановки задачи

$$\min \sum_{i=1}^n f_i(x) \rightarrow \min \sum_{i=1}^n f_i(x_i), \text{ s.t. } x_1 = \dots = x_n$$

# Проксимальный градиентный метод (PGM)

Рассмотрим выпуклую функцию  $f(x)$  такую что

$$f(x) = h(x) + g(x),$$

- ▶  $h(x)$  выпуклая и дифференцируемая
- ▶  $g(x)$  выпуклая и может принимать бесконечные значения  
 $g : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$

Тогда один шаг проксимального градиентного метода

$$x_{k+1} = \text{prox}_{\alpha_k g}(x_k - \alpha_k h'(x_k))$$

- ▶ Скорость сходимости  $\mathcal{O}(1/k)$  для шага  $\alpha_k \equiv \alpha \in (0, 1/L]$ , где  $L$  константа Липшица для градиента  $f'$
- ▶ Возможен адаптивный подбор  $L$

## Почему это работает?

$$\begin{aligned}x_{k+1} &= \arg \min_x \left( g(x) + \frac{1}{2\alpha_k} \|x - (x_k - \alpha_k h'(x_k))\|_2^2 \right) \\&= \arg \min_x \left( g(x) + h(x_k) + \langle h'(x_k), x - x_k \rangle + \frac{1}{2\alpha_k} \|x - x_k\|_2^2 \right)\end{aligned}$$

- ▶ Аналог градиентного спуска, но для композитной целевой функции
- ▶ Для негладкой функции  $f$  использование гладкой компоненты  $h$  повышает скорость сходимости

## Частные случаи

- ▶ Если  $g(x)$  индикаторная функция некоторого выпуклого множества  $G$

$$g(x) = \begin{cases} 0 & x \in G \\ +\infty & x \notin G \end{cases}$$

PGM – метод проекции градиента

$$prox_g(y) = \arg \min_{u \in G} (\|y - u\|_2^2) \equiv \pi_G(y)$$

- ▶ Если  $h \equiv 0$ , тогда PGM – проксимальный метод
- ▶ Если  $g \equiv 0$ , тогда PGM – градиентный спуск

# Ускоренный PGM

- ▶ Сходимость PGM аналогична сходимости градиентного спуска
- ▶ Известно, что такую сходимость можно ускорить
- ▶ Ускоренный PGM
  1.  $y_1 = x_0, t_1 = 1, k = 1$
  2.  $x_k = \text{prox}_{\alpha_k g}(y_k - \alpha_k h'(y_k))$
  3.  $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$
  4.  $y_{k+1} = x_k + \left(\frac{t_k - 1}{t_{k+1}}\right)(x_k - x_{k-1})$
- ▶ Сходимость  $\mathcal{O}(1/k^2)$
- ▶ Доказательство занимает страницу, см [тут](#)

Пример: PGM для такой задачи называется FISTA

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$$

- ▶  $h(x) = \frac{1}{2} \|Ax - y\|_2^2$
- ▶  $g(x) = \gamma \|x\|_1$

### Soft thresholding

- ▶  $prox_{\alpha\|x\|_1}(x)_i = prox_{\alpha|\cdot|}(x_i)$
- ▶  $prox_{\alpha|\cdot|}(x_i) = \arg \min_u (|u| + 1/(2\alpha)(x_i - u)^2)$
- ▶ Аналитическое решение


$$prox_{\alpha|\cdot|}(x_i) = \begin{cases} x_i - \alpha & x_i \geq \alpha \\ 0 & |x_i| \leq \alpha \\ x_i + \alpha & x_i \leq -\alpha \end{cases}$$

- ▶ Векторизованный ответ

$$prox_{\alpha\|x\|_1}(x) = \text{sign}(x)(|x| - \alpha)_+, \quad |x| = (|x_1|, \dots, |x_n|)$$



# Сравнение



# Направления исследований

- ▶ Неевклидовы расстояния в качестве прокс-слагаемого.  
Зеркальный спуск
- ▶ Невыпуклые задачи определённой структуры
- ▶ Параллельные и распределённые реализации
- ▶ Различные способы дискретизаций ОДУ дают новые методы оптимизации, подробности [тут](#)