

Методы оптимизации
Лекция 9: Метод сопряжённых градиентов,
метод тяжёлого шарика и
ускоренный градиентный метод Нестерова

Александр Катруца

Московский физико-технический институт

31 марта 2021 г.

На прошлой лекции

- ▶ Введение в численные методы оптимизации
- ▶ Скорости сходимости методов
- ▶ Градиентный спуск
- ▶ Понятие о нижних оценках сходимости

Что нам известно?

Что нам известно?

Нижние оценки сходимости линейных методов первого порядка:

- ▶ для выпуклых функций с Липшицевым градиентом

$$f(x_{k+1}) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

- ▶ для сильно выпуклых функций с Липшицевым градиентом

$$f(x_{k+1}) - f^* \geq \frac{\mu}{2} \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^{2k} \|x_0 - x^*\|_2^2$$

Что нам известно?

Нижние оценки сходимости линейных методов первого порядка:

- ▶ для выпуклых функций с Липшицевым градиентом

$$f(x_{k+1}) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

- ▶ для сильно выпуклых функций с Липшицевым градиентом

$$f(x_{k+1}) - f^* \geq \frac{\mu}{2} \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^{2k} \|x_0 - x^*\|_2^2$$

Сходимость градиентного спуска:

- ▶ для выпуклых функций с Липшицевым градиентом

$$f(x_{k+1}) - f^* \leq \frac{2L\|x - x_0\|_2^2}{k+4}$$

- ▶ для сильно выпуклых функций с Липшицевым градиентом

$$f(x_k) - f^* \leq \frac{L}{2} \left(\frac{\kappa - 1}{\kappa + 1} \right)^{2k} \|x_0 - x^*\|_2^2$$

Метод сопряжённых градиентов: постановка задачи

- Рассмотрим задачу

$$\min_{x \in \mathbb{R}^n} f(x),$$

где $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ и $A \in \mathbb{S}_{++}^n$

Метод сопряжённых градиентов: постановка задачи

- ▶ Рассмотрим задачу

$$\min_{x \in \mathbb{R}^n} f(x),$$

где $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ и $A \in \mathbb{S}_{++}^n$

- ▶ Из необходимого условия экстремума имеем

$$Ax^* = b$$

Метод сопряжённых градиентов: постановка задачи

- ▶ Рассмотрим задачу

$$\min_{x \in \mathbb{R}^n} f(x),$$

где $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ и $A \in \mathbb{S}_{++}^n$

- ▶ Из необходимого условия экстремума имеем

$$Ax^* = b$$

- ▶ Также обозначим $f'(x_k) = Ax_k - b = r_k$

Метод сопряжённых градиентов: постановка задачи

- ▶ Рассмотрим задачу

$$\min_{x \in \mathbb{R}^n} f(x),$$

где $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ и $A \in \mathbb{S}_{++}^n$

- ▶ Из необходимого условия экстремума имеем

$$Ax^* = b$$

- ▶ Также обозначим $f'(x_k) = Ax_k - b = r_k$
- ▶ Задача оптимизации сведена к задаче решения системы линейных уравнений

Немного истории

- ▶ М. Hestenes и Е. Stiefel предложили метод сопряжённых градиентов в 1952 году как *прямой* метод

Немного истории

- ▶ М. Hestenes и Е. Stiefel предложили метод сопряжённых градиентов в 1952 году как *прямой* метод
- ▶ Долгое время считалось, что метод представляет только теоретический интерес поскольку

Немного истории

- ▶ М. Hestenes и Е. Stiefel предложили метод сопряжённых градиентов в 1952 году как *прямой* метод
- ▶ Долгое время считалось, что метод представляет только теоретический интерес поскольку
 - ▶ не работает на логарифмической линейке

Немного истории

- ▶ М. Hestenes и Е. Stiefel предложили метод сопряжённых градиентов в 1952 году как *прямой* метод
- ▶ Долгое время считалось, что метод представляет только теоретический интерес поскольку
 - ▶ не работает на логарифмической линейке
 - ▶ имеет небольшое преимущество перед исключением Гаусса при вычислениях на калькуляторе

Немного истории

- ▶ М. Hestenes и Е. Stiefel предложили метод сопряжённых градиентов в 1952 году как *прямой* метод
- ▶ Долгое время считалось, что метод представляет только теоретический интерес поскольку
 - ▶ не работает на логарифмической линейке
 - ▶ имеет небольшое преимущество перед исключением Гаусса при вычислениях на калькуляторе
- ▶ Метод сопряжённых градиентов необходимо рассматривать как *итерационный метод*, то есть останавливаться до точной сходимости!

Немного истории

- ▶ М. Hestenes и Е. Stiefel предложили метод сопряжённых градиентов в 1952 году как *прямой* метод
- ▶ Долгое время считалось, что метод представляет только теоретический интерес поскольку
 - ▶ не работает на логарифмической линейке
 - ▶ имеет небольшое преимущество перед исключением Гаусса при вычислениях на калькуляторе
- ▶ Метод сопряжённых градиентов необходимо рассматривать как *итерационный метод*, то есть останавливаться до точной сходимости!
- ▶ Подробнее [здесь](#)

Мотивация

- ▶ Сходимость градиентного спуска сильно зависит от числа обусловленности

Мотивация

- ▶ Сходимость градиентного спуска сильно зависит от числа обусловленности
- ▶ Как сделать метод, который для любого числа обусловленности сходился бы как максимум за n итераций?

Мотивация

- ▶ Сходимость градиентного спуска сильно зависит от числа обусловленности
- ▶ Как сделать метод, который для любого числа обусловленности сходился бы как максимум за n итераций?




Рисунок взят [отсюда](#)

Сопряжённые направления

Определение

Множество ненулевых векторов $\{p_0, \dots, p_l\}$ называется сопряжёнными относительно матрицы $A \in \mathbb{S}_{++}^n$, если

$$p_i^\top A p_j = 0, \quad i \neq j$$

Сопряжённые направления

Определение

Множество ненулевых векторов $\{p_0, \dots, p_l\}$ называется сопряжёнными относительно матрицы $A \in \mathbb{S}_{++}^n$, если

$$p_i^\top A p_j = 0, \quad i \neq j$$

Свойства

Сопряжённые направления

Определение

Множество ненулевых векторов $\{p_0, \dots, p_l\}$ называется сопряжёнными относительно матрицы $A \in \mathbb{S}_{++}^n$, если

$$p_i^\top A p_j = 0, \quad i \neq j$$

Свойства

- ▶ линейно независимы

Сопряжённые направления

Определение

Множество ненулевых векторов $\{p_0, \dots, p_l\}$ называется сопряжёнными относительно матрицы $A \in \mathbb{S}_{++}^n$, если

$$p_i^\top A p_j = 0, \quad i \neq j$$

Свойства

- ▶ линейно независимы
- ▶ сопряжённые направления + шаг по правилу наискорейшего спуска = метод, сходящийся за n итераций

Сопряжённые направления

Определение

Множество ненулевых векторов $\{p_0, \dots, p_l\}$ называется сопряжёнными относительно матрицы $A \in \mathbb{S}_{++}^n$, если

$$p_i^\top A p_j = 0, \quad i \neq j$$

Свойства

- ▶ линейно независимы
- ▶ сопряжённые направления + шаг по правилу наискорейшего спуска = метод, сходящийся за n итераций
- ▶ $x_{k+1} = x_k + \alpha_k p_k \rightarrow r_{k+1} = r_k + \alpha_k A p_k$

Сопряжённые направления

Определение

Множество ненулевых векторов $\{p_0, \dots, p_l\}$ называется сопряжёнными относительно матрицы $A \in \mathbb{S}_{++}^n$, если

$$p_i^\top A p_j = 0, \quad i \neq j$$

Свойства

- ▶ линейно независимы
- ▶ сопряжённые направления + шаг по правилу наискорейшего спуска = метод, сходящийся за n итераций
- ▶ $x_{k+1} = x_k + \alpha_k p_k \rightarrow r_{k+1} = r_k + \alpha_k A p_k$

Q: как получить сопряжённые направления из любого набора линейно независимых векторов?

Сходимость

Теорема

Пусть x_k генерируются методом сопряжённых направлений.

Тогда

1. $\langle r_k, p_i \rangle = 0, \quad i = 1, \dots, k - 1$
2. $x_k = \arg \min_{x \in P} f(x)$, где $P = x_0 + \text{span}(p_0, \dots, p_{k-1})$

Доказательство

Сходимость

Теорема

Пусть x_k генерируются методом сопряжённых направлений.

Тогда

1. $\langle r_k, p_i \rangle = 0, \quad i = 1, \dots, k-1$
2. $x_k = \arg \min_{x \in P} f(x)$, где $P = x_0 + \text{span}(p_0, \dots, p_{k-1})$

Доказательство

1. $\phi(\gamma) = f(x_0 + \gamma_0 p_0 + \dots + \gamma_{k-1} p_{k-1})$

Сходимость

Теорема

Пусть x_k генерируются методом сопряжённых направлений.

Тогда

1. $\langle r_k, p_i \rangle = 0, \quad i = 1, \dots, k - 1$
2. $x_k = \arg \min_{x \in P} f(x),$ где $P = x_0 + \text{span}(p_0, \dots, p_{k-1})$

Доказательство

1. $\phi(\gamma) = f(x_0 + \gamma_0 p_0 + \dots + \gamma_{k-1} p_{k-1})$
2. $\phi(\gamma)$ – строго выпукла \rightarrow существует γ^*

Сходимость

Теорема

Пусть x_k генерируются методом сопряжённых направлений.

Тогда

1. $\langle r_k, p_i \rangle = 0, \quad i = 1, \dots, k-1$
2. $x_k = \arg \min_{x \in P} f(x)$, где $P = x_0 + \text{span}(p_0, \dots, p_{k-1})$

Доказательство

1. $\phi(\gamma) = f(x_0 + \gamma_0 p_0 + \dots + \gamma_{k-1} p_{k-1})$
2. $\phi(\gamma)$ – строго выпукла \rightarrow существует γ^*
3. По критерию первого порядка

$$\phi'(\gamma^*) = \langle f'(x_0 + \gamma_0^* p_0 + \dots + \gamma_{k-1}^* p_{k-1}), p_i \rangle = 0, \quad i = 0, \dots, k-1$$

Сходимость

Теорема

Пусть x_k генерируются методом сопряжённых направлений.

Тогда

1. $\langle r_k, p_i \rangle = 0, i = 1, \dots, k-1$
2. $x_k = \arg \min_{x \in P} f(x)$, где $P = x_0 + \text{span}(p_0, \dots, p_{k-1})$

Доказательство

1. $\phi(\gamma) = f(x_0 + \gamma_0 p_0 + \dots + \gamma_{k-1} p_{k-1})$
2. $\phi(\gamma)$ – строго выпукла \rightarrow существует γ^*
3. По критерию первого порядка

$$\phi'(\gamma^*) = \langle f'(x_0 + \gamma_0^* p_0 + \dots + \gamma_{k-1}^* p_{k-1}), p_i \rangle = 0, i = 0, \dots, k-1$$

4. Из определения r_k следует, что $\langle r_k, p_i \rangle = 0, i = 0, \dots, k-1$

Сходимость

Теорема

Пусть x_k генерируются методом сопряжённых направлений.

Тогда

1. $\langle r_k, p_i \rangle = 0, i = 1, \dots, k-1$
2. $x_k = \arg \min_{x \in P} f(x)$, где $P = x_0 + \text{span}(p_0, \dots, p_{k-1})$

Доказательство

1. $\phi(\gamma) = f(x_0 + \gamma_0 p_0 + \dots + \gamma_{k-1} p_{k-1})$
2. $\phi(\gamma)$ – строго выпукла \rightarrow существует γ^*
3. По критерию первого порядка

$$\phi'(\gamma^*) = \langle f'(x_0 + \gamma_0^* p_0 + \dots + \gamma_{k-1}^* p_{k-1}), p_i \rangle = 0, i = 0, \dots, k-1$$

4. Из определения r_k следует, что $\langle r_k, p_i \rangle = 0, i = 0, \dots, k-1$
5. Таким образом, $(1) \Leftrightarrow (2)$

6. Докажем (1) по индукции:

6. Докажем (1) по индукции:

- ▶ база: $\langle r_1, p_0 \rangle = 0$ по построению

6. Докажем (1) по индукции:

- ▶ база: $\langle r_1, p_0 \rangle = 0$ по построению
- ▶ гипотеза: $\langle r_{k-1}, p_i \rangle = 0, i = 1, \dots, k-2$

6. Докажем (1) по индукции:

- ▶ база: $\langle r_1, p_0 \rangle = 0$ по построению
- ▶ гипотеза: $\langle r_{k-1}, p_i \rangle = 0, i = 1, \dots, k-2$

7. $r_k = r_{k-1} + \alpha_{k-1} A p_{k-1}$

6. Докажем (1) по индукции:

- ▶ база: $\langle r_1, p_0 \rangle = 0$ по построению
- ▶ гипотеза: $\langle r_{k-1}, p_i \rangle = 0, i = 1, \dots, k-2$

7. $r_k = r_{k-1} + \alpha_{k-1} A p_{k-1}$

8. $\langle p_{k-1}, r_k \rangle = \langle p_{k-1}, r_{k-1} \rangle + \alpha_{k-1} \langle p_{k-1}, A p_{k-1} \rangle = 0$ по построению α_{k-1}

6. Докажем (1) по индукции:

- ▶ база: $\langle r_1, p_0 \rangle = 0$ по построению
- ▶ гипотеза: $\langle r_{k-1}, p_i \rangle = 0, i = 1, \dots, k-2$

7. $r_k = r_{k-1} + \alpha_{k-1} A p_{k-1}$

8. $\langle p_{k-1}, r_k \rangle = \langle p_{k-1}, r_{k-1} \rangle + \alpha_{k-1} \langle p_{k-1}, A p_{k-1} \rangle = 0$ по построению α_{k-1}

9. $\langle p_i, r_k \rangle = \langle p_i, r_{k-1} \rangle + \alpha_{k-1} \langle p_i, A p_{k-1} \rangle, i = 1, \dots, k-2$

6. Докажем (1) по индукции:
- ▶ база: $\langle r_1, p_0 \rangle = 0$ по построению
 - ▶ гипотеза: $\langle r_{k-1}, p_i \rangle = 0, i = 1, \dots, k-2$
7. $r_k = r_{k-1} + \alpha_{k-1} A p_{k-1}$
8. $\langle p_{k-1}, r_k \rangle = \langle p_{k-1}, r_{k-1} \rangle + \alpha_{k-1} \langle p_{k-1}, A p_{k-1} \rangle = 0$ по построению α_{k-1}
9. $\langle p_i, r_k \rangle = \langle p_i, r_{k-1} \rangle + \alpha_{k-1} \langle p_i, A p_{k-1} \rangle, i = 1, \dots, k-2$
10. $\langle p_i, r_{k-1} \rangle = 0$ по гипотезе

6. Докажем (1) по индукции:
- ▶ база: $\langle r_1, p_0 \rangle = 0$ по построению
 - ▶ гипотеза: $\langle r_{k-1}, p_i \rangle = 0, i = 1, \dots, k-2$
7. $r_k = r_{k-1} + \alpha_{k-1} A p_{k-1}$
8. $\langle p_{k-1}, r_k \rangle = \langle p_{k-1}, r_{k-1} \rangle + \alpha_{k-1} \langle p_{k-1}, A p_{k-1} \rangle = 0$ по построению α_{k-1}
9. $\langle p_i, r_k \rangle = \langle p_i, r_{k-1} \rangle + \alpha_{k-1} \langle p_i, A p_{k-1} \rangle, i = 1, \dots, k-2$
10. $\langle p_i, r_{k-1} \rangle = 0$ по гипотезе
11. $\langle p_i, A p_{k-1} \rangle = 0$ по свойству сопряжённости $\{p_i\}$

Сопряжённые градиенты

- ▶ $p_0 = -r_0$ — антиградиент

Сопряжённые градиенты

- ▶ $p_0 = -r_0$ — антиградиент
- ▶ $p_{k+1} = -r_{k+1} + \beta_{k+1}p_k$, где β_{k+1} гарантирует сопряжённость p_k и p_{k+1} :

$$p_k^\top A p_{k+1} = p_k^\top A (-r_{k+1} + \beta_{k+1} p_k) = 0$$
$$\beta_{k+1} = \frac{p_k^\top A r_{k+1}}{p_k^\top A p_k}$$

Псевдокод: медленная версия

```
def ConjugateGradientQuadratic(x0, A, b, eps):  
    r = A.dot(x0) - b  
    p = -r  
    while np.linalg.norm(r) > eps:  
        alpha = -r.dot(p) / p.dot(A.dot(p))  
        x = x + alpha * p  
        r = A.dot(x) - b  
        beta = r.dot(A.dot(p)) / p.dot(A.dot(p))  
        p = -r + beta * p  
    return x
```

Ускорение медленной версии

- Вычисление α_k :

$$\alpha_k = -\frac{r_k^\top p_k}{p_k^\top A p_k} = -\frac{r_k^\top (-r_k + \beta_k p_{k-1})}{p_k^\top A p_k} = \frac{\|r_k\|_2^2}{p_k^\top A p_k}$$

Ускорение медленной версии

- Вычисление α_k :

$$\alpha_k = -\frac{r_k^\top p_k}{p_k^\top A p_k} = -\frac{r_k^\top (-r_k + \beta_k p_{k-1})}{p_k^\top A p_k} = \frac{\|r_k\|_2^2}{p_k^\top A p_k}$$

- Вычисление β_k :

$$\beta_{k+1} = \frac{r_{k+1}^\top A p_k}{p_k^\top A p_k} = \frac{r_{k+1}^\top (r_{k+1} - r_k)}{(-r_k + \beta_k p_{k-1})^\top (r_{k+1} - r_k)} = \frac{\|r_{k+1}\|_2^2}{\|r_k\|_2^2}$$

Псевдокод: быстрая версия

```
def ConjugateGradientQuadratic(x0, A, b, eps):  
    r = A.dot(x0) - b  
    p = -r  
    while np.linalg.norm(r) > eps:  
        alpha = r.dot(r) / p.dot(A.dot(p))  
        x = x + alpha * p  
        r_next = r + alpha * A.dot(p)  
        beta = r_next.dot(r_next) / r.dot(r)  
        p = -r_next + beta * p  
        r = r_next  
    return x
```

Почему сопряжённые градиенты сопряжены?

Теорема

Пусть после k итераций $x_k \neq x^*$. Тогда

1. $\langle r_k, r_i \rangle = 0, i = 1, \dots, k-1$
2. $\text{span}(r_0, \dots, r_k) = \text{span}(r_0, Ar_0, \dots, A^k r_0)$
3. $\text{span}(p_0, \dots, p_k) = \text{span}(r_0, Ar_0, \dots, A^k r_0)$
4. $p_k^\top A p_i = 0, i = 1, \dots, k-1$

Крыловское пространство

Определение

Пространство $\mathcal{K}_k(A) = \text{span}(b, Ab, \dots, A^{k-1}b)$ называется пространством Крылова.

Крыловское пространство

Определение

Пространство $\mathcal{K}_k(A) = \text{span}(b, Ab, \dots, A^{k-1}b)$ называется пространством Крылова.

Основное свойство

$$A^{-1}b \in \mathcal{K}_n(A)$$

Крыловское пространство

Определение

Пространство $\mathcal{K}_k(A) = \text{span}(b, Ab, \dots, A^{k-1}b)$ называется пространством Крылова.

Основное свойство

$$A^{-1}b \in \mathcal{K}_n(A)$$

Доказательство

Крыловское пространство

Определение

Пространство $\mathcal{K}_k(A) = \text{span}(b, Ab, \dots, A^{k-1}b)$ называется пространством Крылова.

Основное свойство

$$A^{-1}b \in \mathcal{K}_n(A)$$

Доказательство

- ▶ Теорема Гамильтона-Кэли: $p(A) = 0$, где $p(\lambda) = \det(A - \lambda I)$

Крыловское пространство

Определение

Пространство $\mathcal{K}_k(A) = \text{span}(b, Ab, \dots, A^{k-1}b)$ называется пространством Крылова.

Основное свойство

$$A^{-1}b \in \mathcal{K}_n(A)$$

Доказательство

- ▶ Теорема Гамильтона-Кэли: $p(A) = 0$, где $p(\lambda) = \det(A - \lambda I)$
- ▶ $p(A)b = A^n b + a_1 A^{n-1}b + \dots + a_{n-1}Ab + a_n b = 0$

Крыловское пространство

Определение

Пространство $\mathcal{K}_k(A) = \text{span}(b, Ab, \dots, A^{k-1}b)$ называется пространством Крылова.

Основное свойство

$$A^{-1}b \in \mathcal{K}_n(A)$$

Доказательство

- ▶ Теорема Гамильтона-Кэли: $p(A) = 0$, где $p(\lambda) = \det(A - \lambda I)$
- ▶ $p(A)b = A^n b + a_1 A^{n-1}b + \dots + a_{n-1}Ab + a_n b = 0$
- ▶ $A^{-1}p(A)b = A^{n-1}b + a_1 A^{n-2}b + \dots + a_{n-1}b + a_n A^{-1}b = 0$

Крыловское пространство

Определение

Пространство $\mathcal{K}_k(A) = \text{span}(b, Ab, \dots, A^{k-1}b)$ называется пространством Крылова.

Основное свойство

$$A^{-1}b \in \mathcal{K}_n(A)$$

Доказательство

- ▶ Теорема Гамильтона-Кэли: $p(A) = 0$, где $p(\lambda) = \det(A - \lambda I)$
- ▶ $p(A)b = A^n b + a_1 A^{n-1}b + \dots + a_{n-1}Ab + a_n b = 0$
- ▶ $A^{-1}p(A)b = A^{n-1}b + a_1 A^{n-2}b + \dots + a_{n-1}b + a_n A^{-1}b = 0$
- ▶ $A^{-1}b = -\frac{1}{a_n}(A^{n-1}b + a_1 A^{n-2}b + \dots + a_{n-1}b)$

Интерпретация

- ▶ Поиск лучшего приближения на k -ом Крыловском пространстве

$$x_k = \arg \min_{x \in \mathcal{K}_k} f(x)$$

Интерпретация

- ▶ Поиск лучшего приближения на k -ом Крыловском пространстве

$$x_k = \arg \min_{x \in \mathcal{K}_k} f(x)$$

- ▶ Направления $\{p_i\} \neq \{b, Ab, \dots, A^{k-1}b\}$. Почему?

Интерпретация

- ▶ Поиск лучшего приближения на k -ом Крыловском пространстве

$$x_k = \arg \min_{x \in \mathcal{K}_k} f(x)$$

- ▶ Направления $\{p_i\} \neq \{b, Ab, \dots, A^{k-1}b\}$. Почему?

Краткое описание метода сопряжённых градиентов

Поиск решения в ортонормированном Крыловском базисе

Полезные соотношения

- ▶ Решение: $x^* = A^{-1}b$

Полезные соотношения

- ▶ Решение: $x^* = A^{-1}b$
- ▶ Минимум функции:

$$f^* = \frac{1}{2}b^\top A^{-\top} A A^{-1}b - b^\top A^{-1}b = -\frac{1}{2}b^\top A^{-1}b = -\frac{1}{2}\|x^*\|_A^2$$

Полезные соотношения

- ▶ Решение: $x^* = A^{-1}b$
- ▶ Минимум функции:

$$f^* = \frac{1}{2}b^\top A^{-\top}AA^{-1}b - b^\top A^{-1}b = -\frac{1}{2}b^\top A^{-1}b = -\frac{1}{2}\|x^*\|_A^2$$

- ▶ Оценка сходимости по функции:

$$\begin{aligned}f(x) - f^* &= \frac{1}{2}x^\top Ax - b^\top x + \frac{1}{2}\|x^*\|_A^2 \\&= \frac{1}{2}\|x\|_A^2 - x^\top Ax^* + \frac{1}{2}\|x^*\|_A^2 \\&= \frac{1}{2}\|x - x^*\|_A^2\end{aligned}$$

Сходимость

- ▶ x_k лежит в \mathcal{K}_k

Сходимость

- ▶ x_k лежит в \mathcal{K}_k
- ▶ $x_k = \sum_{i=1}^k c_i A^{i-1} b = p(A)b$, где $p(x)$ некоторый полином степени не выше $k - 1$

Сходимость

- ▶ x_k лежит в \mathcal{K}_k
- ▶ $x_k = \sum_{i=1}^k c_i A^{i-1} b = p(A)b$, где $p(x)$ некоторый полином степени не выше $k - 1$
- ▶ x_k минимизирует f на \mathcal{K}_k , отсюда

$$2(f_k - f^*) = \inf_{x \in \mathcal{K}_k} \|x - x^*\|_A^2 = \inf_{\deg(p) < k} \|(p(A) - A^{-1})b\|_A^2$$

Сходимость

- ▶ x_k лежит в \mathcal{K}_k
- ▶ $x_k = \sum_{i=1}^k c_i A^{i-1} b = p(A)b$, где $p(x)$ некоторый полином степени не выше $k - 1$
- ▶ x_k минимизирует f на \mathcal{K}_k , отсюда

$$2(f_k - f^*) = \inf_{x \in \mathcal{K}_k} \|x - x^*\|_A^2 = \inf_{\deg(p) < k} \|(p(A) - A^{-1})b\|_A^2$$

- ▶ Спектральное разложение $A = U\Lambda U^*$ даёт

$$\begin{aligned} 2(f_k - f^*) &= \inf_{\deg(p) < k} \|(p(\Lambda) - \Lambda^{-1})d\|_\Lambda^2 \\ &= \inf_{\deg(p) < k} \sum_{i=1}^n \frac{d_i^2 (\lambda_i p(\lambda_i) - 1)^2}{\lambda_i} \\ &= \inf_{\deg(q) \leq k, q(0)=1} \sum_{i=1}^n \frac{d_i^2 q(\lambda_i)^2}{\lambda_i} \end{aligned}$$

$$\begin{aligned}
 f_k - f^* &\leq \left(\sum_{i=1}^n \frac{d_i^2}{2\lambda_i} \right) \inf_{\deg(q) \leq k, q(0)=1} \left(\max_{i=1, \dots, n} q(\lambda_i)^2 \right) \\
 &= \frac{1}{2} \|x^*\|_A^2 \inf_{\deg(q) \leq k, q(0)=1} \left(\max_{i=1, \dots, n} q(\lambda_i)^2 \right)
 \end{aligned}$$

- Пусть A имеет m различных собственных значений, тогда для

$$r(y) = \frac{(-1)^m}{\lambda_1 \cdot \dots \cdot \lambda_m} (y - \lambda_1) \cdot \dots \cdot (y - \lambda_m)$$

выполнено $\deg(r) = m$ и $r(0) = 1$

$$\begin{aligned}
 f_k - f^* &\leq \left(\sum_{i=1}^n \frac{d_i^2}{2\lambda_i} \right) \inf_{\deg(q) \leq k, q(0)=1} \left(\max_{i=1, \dots, n} q(\lambda_i)^2 \right) \\
 &= \frac{1}{2} \|x^*\|_A^2 \inf_{\deg(q) \leq k, q(0)=1} \left(\max_{i=1, \dots, n} q(\lambda_i)^2 \right)
 \end{aligned}$$

- Пусть A имеет m различных собственных значений, тогда для

$$r(y) = \frac{(-1)^m}{\lambda_1 \cdot \dots \cdot \lambda_m} (y - \lambda_1) \cdot \dots \cdot (y - \lambda_m)$$

выполнено $\deg(r) = m$ и $r(0) = 1$

- Значение для оптимального полинома степени не выше k оценим сверху значением для полинома r степени m

$$0 \leq f_k - f^* \leq \frac{1}{2} \|x^*\|_A^2 \max_{i=1, \dots, m} r(\lambda_i) = 0$$

$$\begin{aligned}
 f_k - f^* &\leq \left(\sum_{i=1}^n \frac{d_i^2}{2\lambda_i} \right) \inf_{\deg(q) \leq k, q(0)=1} \left(\max_{i=1, \dots, n} q(\lambda_i)^2 \right) \\
 &= \frac{1}{2} \|x^*\|_A^2 \inf_{\deg(q) \leq k, q(0)=1} \left(\max_{i=1, \dots, n} q(\lambda_i)^2 \right)
 \end{aligned}$$

- Пусть A имеет m различных собственных значений, тогда для

$$r(y) = \frac{(-1)^m}{\lambda_1 \cdot \dots \cdot \lambda_m} (y - \lambda_1) \cdot \dots \cdot (y - \lambda_m)$$

выполнено $\deg(r) = m$ и $r(0) = 1$

- Значение для оптимального полинома степени не выше k оценим сверху значением для полинома r степени m

$$0 \leq f_k - f^* \leq \frac{1}{2} \|x^*\|_A^2 \max_{i=1, \dots, m} r(\lambda_i) = 0$$

- Метод сопряжённых градиентов сошёлся за m итераций

Пример задачи

- ▶ $n = 100$
- ▶ Спектр A : $\{1, 10, 100, 1000\}$
- ▶ $\kappa = 1000$






Иллюстрация сходимости



Другие оценки

- ▶ Если $q(x)$ – Чебышёвский полином на $[\lambda_{\min}, \lambda_{\max}]$, то

$$f_k - f^* \leq C \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k$$

- ▶ Если $q(x)$ имеет корни $\lambda_1, \dots, \lambda_{k-1}$ и $(\lambda_1 + \lambda_n)/2$, то

$$f_k - f^* \leq C \left(\frac{\lambda_k - \lambda_n}{\lambda_k + \lambda_n} \right)^2$$

Обобщение на неквадратичную целевую функцию

1. Шаг α_k подбирается адаптивно

Обобщение на неквадратичную целевую функцию

1. Шаг α_k подбирается адаптивно
2. Коэффициент β_k ищется с помощью градиентов
 $f'(x_{k-1}), f'(x_{k-2})$

Обобщение на неквадратичную целевую функцию

1. Шаг α_k подбирается адаптивно
2. Коэффициент β_k ищется с помощью градиентов
 $f'(x_{k-1}), f'(x_{k-2})$

Примеры

Обобщение на неквадратичную целевую функцию

1. Шаг α_k подбирается адаптивно
2. Коэффициент β_k ищется с помощью градиентов $f'(x_{k-1}), f'(x_{k-2})$

Примеры

- Метод Флетчера-Ривса (Fletcher-Reeves)

$$\beta_k = \frac{\|f'(x_{k-1})\|_2^2}{\|f'(x_{k-2})\|_2^2}$$

Обобщение на неквадратичную целевую функцию

1. Шаг α_k подбирается адаптивно
2. Коэффициент β_k ищется с помощью градиентов $f'(x_{k-1}), f'(x_{k-2})$

Примеры

- ▶ Метод Флетчера-Ривса (Fletcher-Reeves)

$$\beta_k = \frac{\|f'(x_{k-1})\|_2^2}{\|f'(x_{k-2})\|_2^2}$$

- ▶ Метод Полака-Рибьера (Polak-Ribière)

$$\beta_k = \frac{\langle f'(x_{k-1}), f'(x_{k-1}) - f'(x_{k-2}) \rangle}{\|f'(x_{k-2})\|_2^2}$$

Обобщение на неквадратичную целевую функцию

1. Шаг α_k подбирается адаптивно
2. Коэффициент β_k ищется с помощью градиентов $f'(x_{k-1}), f'(x_{k-2})$

Примеры

- ▶ Метод Флетчера-Ривса (Fletcher-Reeves)

$$\beta_k = \frac{\|f'(x_{k-1})\|_2^2}{\|f'(x_{k-2})\|_2^2}$$

- ▶ Метод Полака-Рибьера (Polak-Ribière)

$$\beta_k = \frac{\langle f'(x_{k-1}), f'(x_{k-1}) - f'(x_{k-2}) \rangle}{\|f'(x_{k-2})\|_2^2}$$

- ▶ Метод Хестенса-Штифеля (Hestenes-Stiefel)

$$\beta_k = \frac{\langle f'(x_{k-1}), f'(x_{k-1}) - f'(x_{k-2}) \rangle}{\langle p_{k-1}, f'(x_{k-1}) - f'(x_{k-2}) \rangle}$$

Особенности неквадратичного случая

- ▶ С ростом числа итераций направления p_k могут становиться всё более коллинеарными

Особенности неквадратичного случая

- ▶ С ростом числа итераций направления p_k могут становится всё более коллинеарными
- ▶ Помогают рестарты при выполнении некоторых условий

Особенности неквадратичного случая

- ▶ С ростом числа итераций направления p_k могут становится всё более коллинеарными
- ▶ Помогают рестарты при выполнении некоторых условий
- ▶ При выборе α_k по правилу наискорейшего спуска, p_k – направление убывание

Особенности неквадратичного случая

- ▶ С ростом числа итераций направления p_k могут становиться всё более коллинеарными
- ▶ Помогают рестарты при выполнении некоторых условий
- ▶ При выборе α_k по правилу наискорейшего спуска, p_k – направление убывания
- ▶ НЕ при любом способе адаптивного поиска α_k направление $\alpha_k p_k$ будет направлением убывания

Особенности неквадратичного случая

- ▶ С ростом числа итераций направления p_k могут становиться всё более коллинеарными
- ▶ Помогают рестарты при выполнении некоторых условий
- ▶ При выборе α_k по правилу наискорейшего спуска, p_k – направление убывания
- ▶ НЕ при любом способе адаптивного поиска α_k направление $\alpha_k p_k$ будет направлением убывания
- ▶ Интерпретация через квазиньютоновский метод с ограниченной памятью – через две недели

Метод тяжёлого шарика (Б. Т. Поляк, 1964)

$$x_{k+1} = x_k - \alpha_k f'(x_k) + \beta_k (x_k - x_{k-1})$$





Рисунок взят [отсюда](#)

- ▶ Двухшаговый немонотонный метод
- ▶ Дискретизация следующего дифференциального уравнения

$$\ddot{x} + b\dot{x} + af'(x) = 0$$

- ▶ Метод сопряжённых градиентов — частный случай

Сходимость для сильно выпуклой функции

- Перепишем метод как

$$\begin{bmatrix} x_{k+1} \\ x_k \end{bmatrix} = \begin{bmatrix} (1 + \beta_k)I & -\beta_k I \\ I & 0 \end{bmatrix} \begin{bmatrix} x_k \\ x_{k-1} \end{bmatrix} + \begin{bmatrix} -\alpha_k f'(x_k) \\ 0 \end{bmatrix}$$

Сходимость для сильно выпуклой функции

- Перепишем метод как

$$\begin{bmatrix} x_{k+1} \\ x_k \end{bmatrix} = \begin{bmatrix} (1 + \beta_k)I & -\beta_k I \\ I & 0 \end{bmatrix} \begin{bmatrix} x_k \\ x_{k-1} \end{bmatrix} + \begin{bmatrix} -\alpha_k f'(x_k) \\ 0 \end{bmatrix}$$

- Используем теорему из анализа

$$\begin{bmatrix} x_{k+1} - x^* \\ x_k - x^* \end{bmatrix} = \underbrace{\begin{bmatrix} (1 + \beta_k)I - \alpha_k \int_0^1 f''(x(\tau))d\tau & -\beta_k I \\ I & 0 \end{bmatrix}}_{=A_t} \begin{bmatrix} x_k - x^* \\ x_{k-1} - x^* \end{bmatrix}$$

где $x(\tau) = x_k + \tau(x^* - x_k)$

Сходимость для сильно выпуклой функции

- Перепишем метод как

$$\begin{bmatrix} x_{k+1} \\ x_k \end{bmatrix} = \begin{bmatrix} (1 + \beta_k)I & -\beta_k I \\ I & 0 \end{bmatrix} \begin{bmatrix} x_k \\ x_{k-1} \end{bmatrix} + \begin{bmatrix} -\alpha_k f'(x_k) \\ 0 \end{bmatrix}$$

- Используем теорему из анализа

$$\begin{bmatrix} x_{k+1} - x^* \\ x_k - x^* \end{bmatrix} = \underbrace{\begin{bmatrix} (1 + \beta_k)I - \alpha_k \int_0^1 f''(x(\tau))d\tau & -\beta_k I \\ I & 0 \end{bmatrix}}_{=A_t} \begin{bmatrix} x_k - x^* \\ x_{k-1} - x^* \end{bmatrix}$$

где $x(\tau) = x_k + \tau(x^* - x_k)$

- Сходимость зависит от спектрального радиуса матрицы итераций A_t

Сходимость для сильно выпуклой функции

- Перепишем метод как

$$\begin{bmatrix} x_{k+1} \\ x_k \end{bmatrix} = \begin{bmatrix} (1 + \beta_k)I & -\beta_k I \\ I & 0 \end{bmatrix} \begin{bmatrix} x_k \\ x_{k-1} \end{bmatrix} + \begin{bmatrix} -\alpha_k f'(x_k) \\ 0 \end{bmatrix}$$

- Используем теорему из анализа

$$\begin{bmatrix} x_{k+1} - x^* \\ x_k - x^* \end{bmatrix} = \underbrace{\begin{bmatrix} (1 + \beta_k)I - \alpha_k \int_0^1 f''(x(\tau))d\tau & -\beta_k I \\ I & 0 \end{bmatrix}}_{=A_t} \begin{bmatrix} x_k - x^* \\ x_{k-1} - x^* \end{bmatrix}$$

где $x(\tau) = x_k + \tau(x^* - x_k)$

- Сходимость зависит от спектрального радиуса матрицы итераций A_t
- Выберем α_k и β_k так, чтобы минимизировать спектральный радиус

Выбор параметров

Теорема

Пусть f выпуклая с Липшицевым градиентом и сильно выпуклая функция. Тогда $\alpha_k = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}$ и


$\beta_k = \max(|1 - \sqrt{\alpha_k L}|, |1 - \sqrt{\alpha_k \mu}|)^2$ дают

$$\left\| \begin{bmatrix} x_{k+1} - x^* \\ x_k - x^* \end{bmatrix} \right\|_2 \leq \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \left\| \begin{bmatrix} x_1 - x^* \\ x_0 - x^* \end{bmatrix} \right\|_2$$

- ▶ Параметры зависят от L и μ
- ▶ Быстрее чем градиентный спуск
- ▶ Аналог CG для сильно выпуклой квадратичной функции

Иллюстрация

- ▶ $n = 100$
- ▶ Случайная квадратичная задача



Ускоренный градиентный метод (Нестеров, 1983)

Один из вариантов

$$y_0 = x_0$$

$$x_{k+1} = y_k - \alpha_k f'(y_k)$$

$$y_{k+1} = x_{k+1} + \frac{k}{k+3}(x_{k+1} - x_k)$$

Ускоренный градиентный метод (Нестеров, 1983)

Один из вариантов

$$y_0 = x_0$$

$$x_{k+1} = y_k - \alpha_k f'(y_k)$$

$$y_{k+1} = x_{k+1} + \frac{k}{k+3}(x_{k+1} - x_k)$$

- ▶ Сравнение с методом тяжёлого шарика

Ускоренный градиентный метод (Нестеров, 1983)

Один из вариантов

$$y_0 = x_0$$

$$x_{k+1} = y_k - \alpha_k f'(y_k)$$

$$y_{k+1} = x_{k+1} + \frac{k}{k+3}(x_{k+1} - x_k)$$

- ▶ Сравнение с методом тяжёлого шарика
- ▶ Немонотонный

Ускоренный градиентный метод (Нестеров, 1983)

Один из вариантов


$$y_0 = x_0$$

$$x_{k+1} = y_k - \alpha_k f'(y_k)$$

$$y_{k+1} = x_{k+1} + \frac{k}{k+3}(x_{k+1} - x_k)$$

- ▶ Сравнение с методом тяжёлого шарика
- ▶ Немонотонный
- ▶ Интерпретация как дискретизация некоторого ОДУ

Визуализация итераций



Сходимость

Теорема

Пусть f выпукла с Липшицевым градиентом, а шаг $\alpha_k = \frac{1}{L}$.
Тогда ускоренный градиентный метод сходится как

$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|_2^2}{(k+1)^2} = \mathcal{O}(1/k^2)$$

Сходимость

Теорема

Пусть f выпукла с Липшицевым градиентом, а шаг $\alpha_k = \frac{1}{L}$. Тогда ускоренный градиентный метод сходится как


$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|_2^2}{(k+1)^2} = \mathcal{O}(1/k^2)$$

Теорема

Ускоренный метод Нестерова для сильно выпуклой функции при шаге $\alpha_k = \frac{1}{L}$ сходится как

$$f(x_k) - f^* \leq L\|x_k - x_0\|_2^2 \left(1 - \frac{1}{\sqrt{\kappa}}\right)^k$$

Пример сходимости



Что мы знаем?

- ▶ Сходимость градиентного спуска может быть улучшена

Что мы знаем?

- ▶ Сходимость градиентного спуска может быть улучшена
- ▶ Метод сопряжённых градиентов надо использовать для квадратичных сильно выпуклых функций

Что мы знаем?

- ▶ Сходимость градиентного спуска может быть улучшена
- ▶ Метод сопряжённых градиентов надо использовать для квадратичных сильно выпуклых функций
- ▶ Ускоренный метод Нестерова оптимален для выпуклых с Липшицевым градиентом и сильно выпуклых функций

Что мы знаем?

- ▶ Сходимость градиентного спуска может быть улучшена
- ▶ Метод сопряжённых градиентов надо использовать для квадратичных сильно выпуклых функций
- ▶ Ускоренный метод Нестерова оптимален для выпуклых с Липшицевым градиентом и сильно выпуклых функций

Вопросы

Что мы знаем?

- ▶ Сходимость градиентного спуска может быть улучшена
- ▶ Метод сопряжённых градиентов надо использовать для квадратичных сильно выпуклых функций
- ▶ Ускоренный метод Нестерова оптимален для выпуклых с Липшицевым градиентом и сильно выпуклых функций

Вопросы

- ▶ Что делать, когда нельзя точно посчитать градиент?

Что мы знаем?

- ▶ Сходимость градиентного спуска может быть улучшена
- ▶ Метод сопряжённых градиентов надо использовать для квадратичных сильно выпуклых функций
- ▶ Ускоренный метод Нестерова оптимален для выпуклых с Липшицевым градиентом и сильно выпуклых функций

Вопросы

- ▶ Что делать, когда нельзя точно посчитать градиент?
- ▶ Все методы зависят от неизвестных констант, как подбирать шаги адаптивно?

Что мы знаем?

- ▶ Сходимость градиентного спуска может быть улучшена
- ▶ Метод сопряжённых градиентов надо использовать для квадратичных сильно выпуклых функций
- ▶ Ускоренный метод Нестерова оптимален для выпуклых с Липшицевым градиентом и сильно выпуклых функций

Вопросы

- ▶ Что делать, когда нельзя точно посчитать градиент?
- ▶ Все методы зависят от неизвестных констант, как подбирать шаги адаптивно?
- ▶ Что произойдёт со скоростями сходимости?

- ▶ Метод сопряжённых градиентов

Резюме

- ▶ Метод сопряжённых градиентов
- ▶ Метод тяжёлого шарика

Резюме

- ▶ Метод сопряжённых градиентов
- ▶ Метод тяжёлого шарика
- ▶ Ускоренный градиентный метод Нестерова